Chapter 04 CPU 스케쥴링

Contents

- 01 스케줄링의 개요
- 02 스케줄링 시 고려 사항
- 03 다중 큐
- 04 스케줄링 알고리즘
- 04 [심화학습] 인터럽트 처리

학습목표

- CPU 스케줄링의 의미를 이해하고 단계와 목적을 알아본다.
- 스케줄링 시 고려할 사항을 알아본다.
- 준비 상태와 대기 상태에서 다중 큐가 어떻게 운영되는지 알아본다.
- 스케줄링 알고리즘의 종류와 각 방식의 장단점을 파악한다.

1-1 식당 관리자의 스케줄링

■ 식당 관리자의 역할

예약 관리

좌석 관리

주문 관리

조리 순서 관리

손님 요청 관리



그림 4-1 식당 관리자의 역할

1-1 식당 관리자의 스케줄링

CPU 스케줄러

- 운영체제에서 식당 관리자의 역할을 담당
- 여러 프로세스의 상황을 고려하여 CPU와 시스템 자원의 배정을 결정



그림 4-2 조리 순서 변경

■ 고수준 스케줄링

- 시스템 내의 전체 작업 수를 조절하는 것
- 어떤 작업을 시스템이 받아들일지 또는 거부할지를 결정
- 시스템 내에서 동시에 실행 가능한 프로세스의 총개수가 정해짐
- 장기 스케줄링, 작업 스케줄링, 승인 스케줄링이라고도 함

■ 저수준 스케줄링

- 어떤 프로세스에 CPU를 할당할지, 어떤 프로세스를 대기 상태로 보낼지 등을 결정
- 아주 짧은 시간에 일어나기 때문에 단기 스케줄링이라고도 함

■ 중간 수준 스케줄링

- 중지와 활성화로 전체 시스템의 활성화된 프로세스 수를 조절하여 과부하를 막음
- 일부 프로세스를 중지 상태로 옮김으로써 나머지 프로세스가 원만하게 작동하도록
 지원
- 저수준 스케줄링이 원만하게 이루어지도록 완충하는 역할

정리

고수준 스케줄링	전체 시스템의 부하를 고려하여 작업을 시작할지 말지를 결 정
중간 수준 스케일링	시스템에 과부하가 걸려서 전체 프로세스 수를 조절해야 한 다면 이미 활성화된 프로세스 중 일부를 보류 상태로 보냄
저수준 스케줄링	실제 작업을 수행

정리

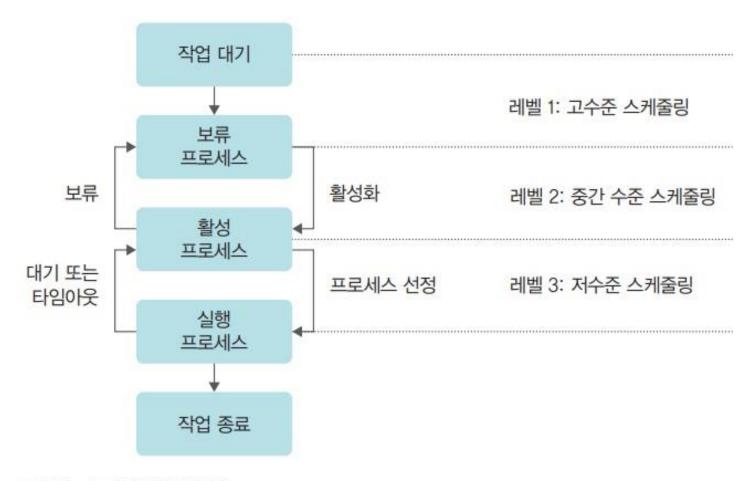


그림 4-3 스케줄링의 단계

1-3 스케줄링의 목적

CPU 스케줄링의 목적

무한 연기 방지	특정 프로세스의 작업이 무한히 연기되어서는 안 됨
반응 시간 보장	응답이 없는 경우 사용자는 시스템이 멈춘 것으로 가정하기 때문에 시스템은 적절한 시간 안에 프로세스의 요구에 반응해야 함
확장성	프로세스가 증가해도 시스템이 안정적으로 작동하도록 조치해야 하며 시스템 자원이 늘어나는 경우 이 혜택이 시스템에 반영되게 해야 함
안정성	우선순위를 사용하여 중요 프로세스가 먼저 작동하도록 배정함으로써 시스템 자원을 점유하거나 파괴하려는 프로세스로부터 자원을 보호해야 함
효율성	시스템 자원이 유휴 시간 없이 사용되도록 스케줄링을 하고, 유휴 자원을 사용하려는 프로세스에는 우선권을 주어야 함
공평성	모든 프로세스가 자원을 공평하게 배정받아야 하며, 자원 배정 과정에서 특정 프로세스가 배제되어서는 안 됨

2-1 선점형 스케줄링과 비선점형 스케줄링

■ 선점형 스케줄링

- 운영체제가 필요하다고 판단하면 실행 상태에 있는 프로세스의 작업을 중단시키고 새로
 운 작업을 시작할 수 있는 방식
- 하나의 프로세스가 CPU를 독점할 수 없기 때문에 빠른 응답 시간을 요구하는 대화형 시 스템이나 시분할 시스템에 적합
- 대부분의 저수준 스케줄러는 선점형 스케줄링 방식을 사용

📘 비선점형 스케줄링

- 어떤 프로세스가 실행 상태에 들어가 CPU를 사용하면 그 프로세스가 종료되거나 자발적으로 대기 상태에 들어가기 전까지는 계속 실행되는 방식
- 선점형 스케줄링보다 스케줄러의 작업량이 적고 문맥 교환에 의한 낭비도 적음
- CPU 사용 시간이 긴 프로세스 때문에 CPU 사용 시간이 짧은 여러 프로세스가 오랫동안
 기다리게 되어 전체 시스템의 처리율이 떨어짐
- 과거의 일괄 작업 시스템에서 사용하던 방식

2-1 선점형 스케줄링과 비선점형 스케줄링

표 4-1 선점형 스케줄링과 비선점형 스케줄링의 비교

구분	선점형	비선점형
작업 방식	실행 상태에 있는 작업을 중단시키고 새로운 작업을 실행할 수 있다.	실행 상태에 있는 작업이 완료될 때까지 다른 작업 이 불가능하다.
장점	프로세스가 CPU를 독점할 수 없어 대화형이나 시분 할 시스템에 적합하다.	CPU 스케줄러의 작업량이 적고 문맥 교환의 오 버헤드가 적다.
단점	문맥 교환의 오버헤드가 많다.	기다리는 프로세스가 많아 처리율이 떨어진다.
사용	시분할 방식 스케줄러에 사용된다.	일괄 작업 방식 스케줄러에 사용된다.
중요도	높다.	낮다.

2-2 프로세스 우선순위

📘 프로세스 우선순위

- 커널 프로세스의 우선순위가 일반 프로세스보다 높음
- 시스템에는 다양한 우선순위의 프로세스가 공존하며 우선순위가 높은 프로세스가
 CPU를 먼저, 더 오래 차지
- 시스템에 따라 높은 숫자가 높은 우선순위를 나타내기도 하고, 낮은 숫자가 높은
 우선순위를 나타내기도 함

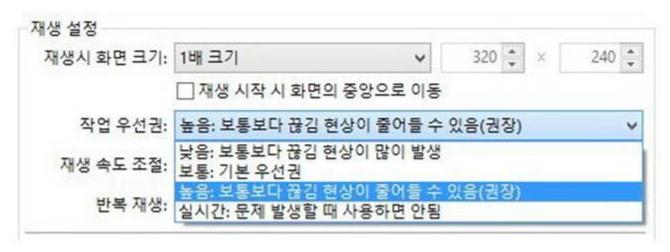


그림 4-4 윈도우의 우선 순위 조절

2-3 CPU 집중 프로세스와 입출력 집중 프로세스

CPU 집중 프로세스

■ 수학 연산과 같이 CPU를 많이 사용하는 프로세스로 CPU 버스트가 많은 프로세스

■ 입출력 집중 프로세스

 저장장치에서 데이터를 복사하는 일과 같이 입출력을 많이 사용하는 프로세스로 입 출력 버스트가 많은 프로세스

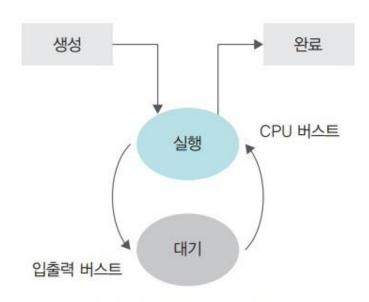
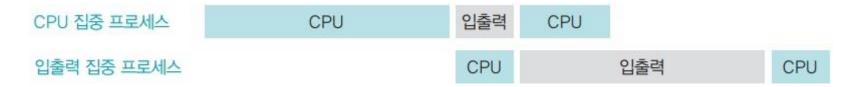


그림 4-5 CPU 버스트와 입출력 버스트

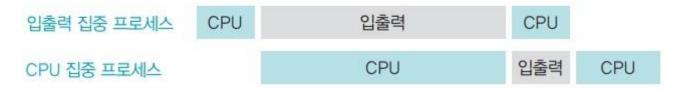
2-3 CPU 집중 프로세스와 입출력 집중 프로세스

■ 우선 배정

스케줄링을 할 때 입출력 집중 프로세스의 우선순위를 CPU 집중 프로세스보다 높이면 시스템의 효율이 향상



(a) CPU 집중 프로세스 우선 배정



(b) 입출력 집중 프로세스 우선 배정

그림 4-6 CPU 집중 프로세스와 입출력 집중 프로세스의 우선 배정 결과

2-4 전면 프로세스와 후면 프로세스

■ 전면 프로세스

- GUI를 사용하는 운영체제에서 화면의 맨 앞에 놓인 프로세스
- 현재 입력과 출력을 사용하는 프로세스
- 사용자와 상호작용이 가능하여 상호작용 프로세스라고도 함

■ 후면 프로세스

- 사용자와 상호작용이 없는 프로세스
- 사용자의 입력 없이 작동하기 때문에 일괄 작업 프로세스라고도 함
- 전면 프로세스의 우선순위가 후면 프로세스보다 높음

2-4 전면 프로세스와 후면 프로세스

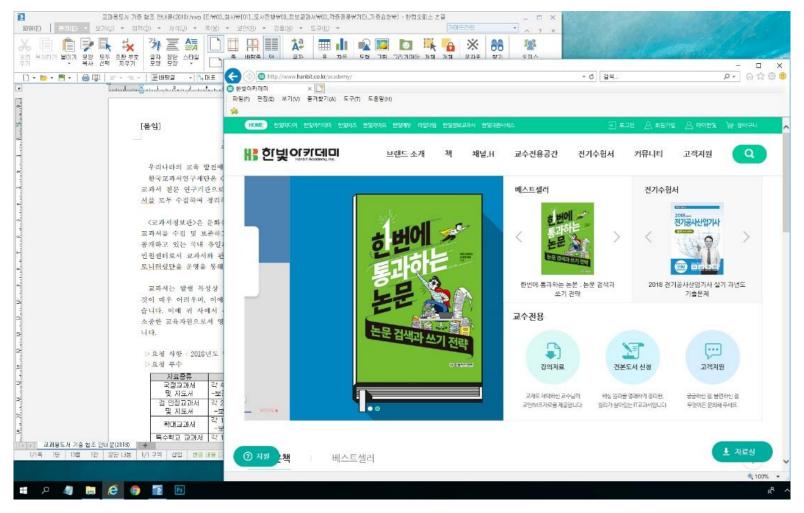
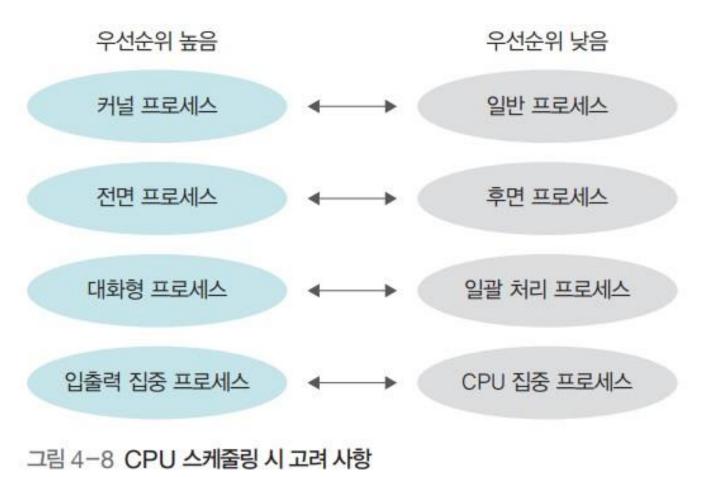


그림 4-7 전면 프로세스와 후면 프로세스의 예

2-5 정리

CPU 스케줄링 시 고려사항



3-1 준비 상태의 다중 큐

■ 준비 상태의 다중 큐

프로세스는 준비 상태에 들어올 때마다 자신의 우선순위에 해당하는 큐의 마지막
 에 삽입

■ CPU 스케줄러는 우선순위가 가장 높은 큐(0번 큐)의 맨 앞에 있는 프로세스 6에

CPU 할당

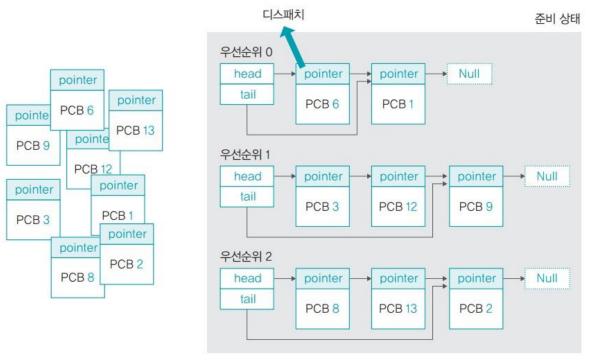


그림 4-9 준비 상태의 다중 큐

3-1 준비 상태의 다중 큐

프로세스의 우선순위를 배정하는 방식

- 고정 우선순위 방식
 - 운영체제가 프로세스에 우선순위를 부여하면 프로세스가 끝날 때까지 바뀌지 않는 방식
 - 프로세스가 작업하는 동안 우선순위가 변하지 않기 때문에 구현하기 쉽지만,
 시스템의 상황이 시시각각 변하는데 우선순위를 고정하면 시스템의 변화에 대응하기 어려워 작업 효율이 떨어짐
- 변동 우선순위 방식
 - 프로세스 생성 시 부여받은 우선순위가 프로세스 작업 중간에 변하는 방식
 - 구현하기 어렵지만 시스템의 효율성을 높일 수 있음

3-2 대기 상태의 다중 큐

📘 대기 상태의 다중 큐

시스템의 효율을 높이기 위해 대기 상태에서는 같은 입출력을 요구한 프로세스끼리 모아 놓음

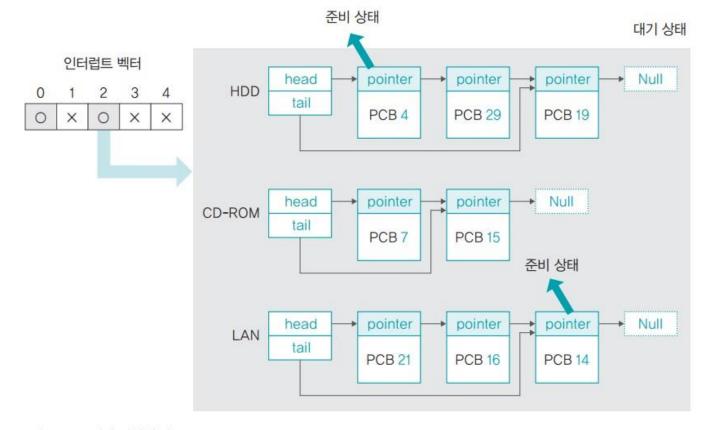


그림 4-10 대기 상태의 다중 큐

3-2 대기 상태의 다중 큐

📘 다중 큐 비교

- 준비큐
 - 한 번에 하나의 프로세스를 꺼내어 CPU를 할당
- 대기 큐
 - 여러 개의 프로세스 제어 블록을 동시에 꺼내어 준비 상태로 옮김
 - 대기 큐에서 동시에 끝나는 인터럽트를 처리하기 위해 인터럽트 벡터라는
 자료 구조 사용

3-2 대기 상태의 다중 큐

다중 큐

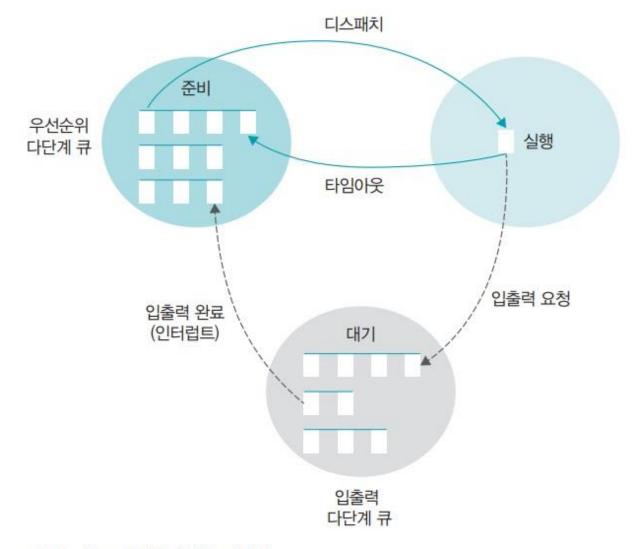


그림 4-11 프로세스 상태와 다중 큐

표 4-2 스케줄링 알고리즘의 종류

구분	종류
비선점형 알고리즘	FCFS 스케줄링, SJF 스케줄링, HRN 스케줄링
선점형 알고리즘	라운드 로빈 스케줄링, SRT 스케줄링, 다단계 큐 스케줄링, 다단계 피드백 큐 스케줄링
둘다가능	우선순위 스케줄링

스케줄링 알고리즘의 평가 기준

- CPU 사용률
 - 전체 시스템의 동작 시간 중 CPU가 사용된 시간을 측정하는 방법
 - 가장 이상적인 수치는 100%이지만 실제로는 여러 가지 이유로 90%에도 못 미침
- 처리량
 - 단위 시간당 작업을 마친 프로세스의 수
 - 이 수치가 클수록 좋은 알고리즘임

■ 스케줄링 알고리즘의 평가 기준

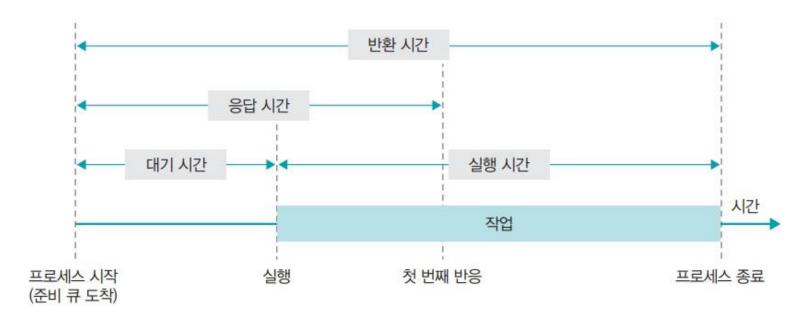


그림 4-12 대기 시간, 응답 시간, 실행 시간, 반환 시간의 관계

- **대기 시간** : 프로세스가 생성된 후 실행되기 전까지 대기하는 시간
- 응답 시간 : 첫 작업을 시작한 후 첫 번째 출력(반응)이 나오기까지의 시간
- 실행 시간 : 프로세스 작업이 시작된 후 종료되기까지의 시간
- 반환 시간 : 대기 시간을 포함하여 실행이 종료될 때까지의 시간

■ 평균 대기 시간

■ 모든 프로세스의 대기 시간을 합한 뒤 프로세스의 수로 나눈 값

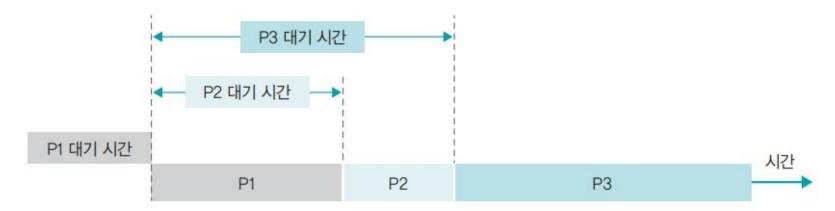


그림 4-13 평균 대기 시간

4-2 FCFS 스케줄링

■ FCFS 스케줄링의 동작 방식

- 준비 큐에 도착한 순서대로 CPU를 할당하는 비선점형 방식
- 한 번 실행되면 그 프로세스가 끝나야만 다음 프로세스를 실행할 수 있음
- 큐가 하나라 모든 프로세스는 우선순위가 동일

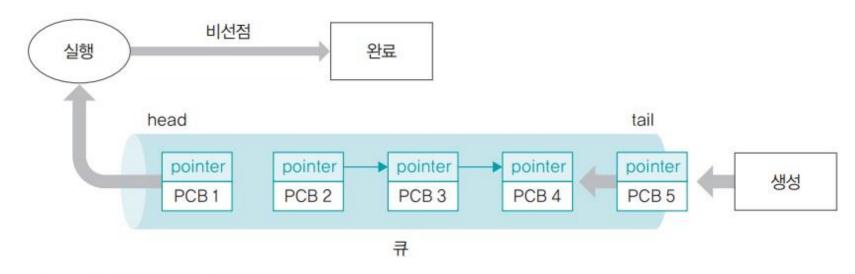


그림 4-14 FCFS 스케줄링의 동작

4-2 FCFS 스케줄링

■ FCFS 스케줄링의 성능

도착순서	도착시간	작업 시간
P1	0	30
P2	3	18
P3	6	9

※ 평균 대기 시간 (0+27+42)÷3=23밀리초

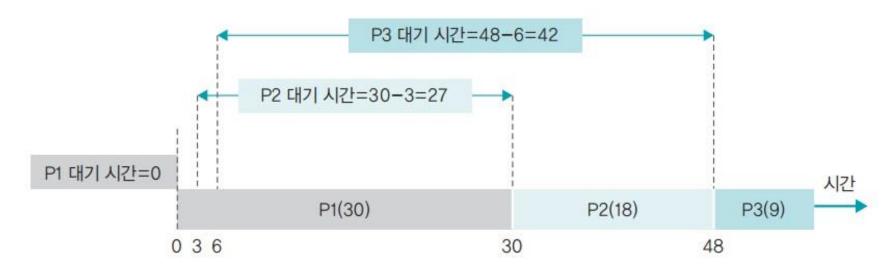


그림 4-15 FCFS 스케줄링의 평균 대기 시간

4-2 FCFS 스케줄링

FCFS 스케줄링의 평가

- 처리 시간이 긴 프로세스가 CPU를 차지하면 다른 프로세스들은 하염없이 기다려 시스템의 효율성이 떨어짐
- 특히 현재 작업 중인 프로세스가 입출력 작업을 요청하는 경우 CPU가 작업하지 않고 쉬는 시간이 많아져 작업 효율이 떨어짐

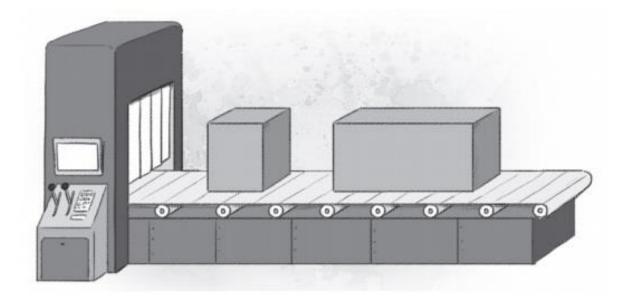


그림 4-16 콘보이 효과

4-3 SJF 스케줄링

SJF 스케줄링의 동작 방식

- 준비 큐에 있는 프로세스 중에서 실행 시간이 가장 짧은 작업부터 CPU를 할당하는 비선점형 방식
- 최단 작업 우선 스케줄링이라고도 함
- 콘보이 효과를 완화하여 시스템의 효율성을 높임

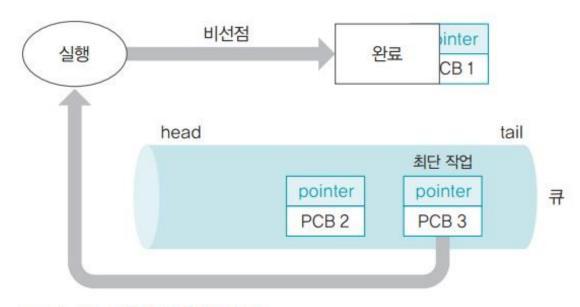


그림 4-17 SJF 스케줄링의 동작

4-3 SJF 스케줄링

SJF 스케줄링의 성능

도착순서	도착시간	작업 시간
P1	0	30
P2	3	18
P3	6	9

※ 평균 대기 시간 (0+24+36)÷3=20밀리초

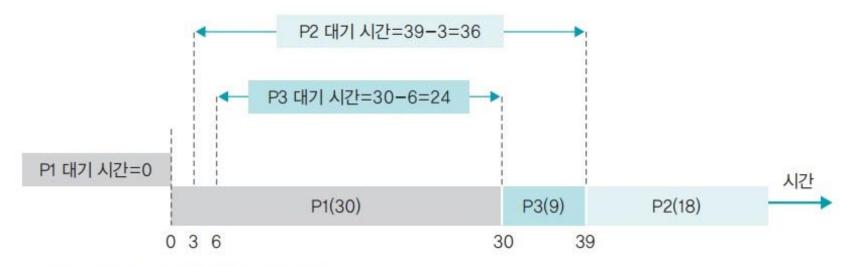


그림 4-18 SJF 스케줄링의 평균 대기 시간

4-3 SJF 스케줄링

SJF 스케줄링의 평가

- 운영체제가 프로세스의 종료 시간을 정확하게 예측하기 어려움
- 작업 시간이 길다는 이유만으로 계속 뒤로 밀려 공평성이 현저히 떨어짐. 이를 아사(starvation) 현상 이라 부름

■ 에이징(나이 먹기)

- 아사 현상의 완화 방법
- 프로세스가 양보할 수 있는 상한선을 정하는 방식
- 프로세스가 자신의 순서를 양보할 때마다 나이를 한 살씩 먹어 최대 몇 살까지 양
 보하도록 규정하는 것

4-4 HRN 스케줄링

■ HRN 스케줄링의 동작 방식

- SJF 스케줄링에서 발생할 수 있는 아사 현상을 해결하기 위해 만들어진 비선점형 알고리즘
- 최고 응답률 우선 스케줄링이라고도 함
- 서비스를 받기 위해 기다린 시간과 CPU 사용 시간을 고려하여 스케줄링을 하는 방식
- 프로세스의 우선순위를 결정하는 기준

4-4 HRN 스케줄링

■ HRN 스케줄링의 성능

도착 순서	도착시간	작업 시간
P1	0	30
P2	3	18
P3	6	9

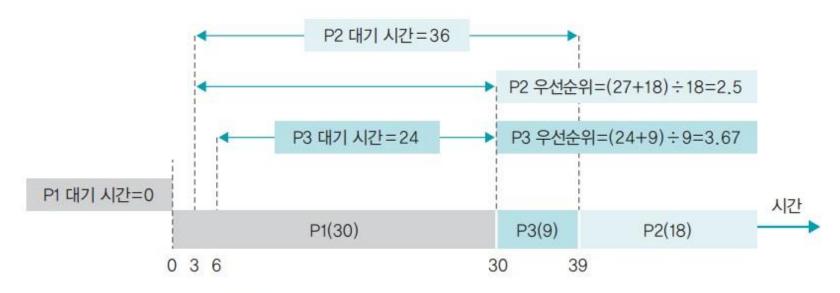


그림 4-19 HRN 스케줄링의 평균 대기 시간

4-4 HRN 스케줄링

■ HRN 스케줄링의 평가

- 실행 시간이 짧은 프로세스의 우선순위를 높게 설정하면서도 대기 시간을 고려하여
 여 아사 현상을 완화
- 대기 시간이 긴 프로세스의 우선순 위를 높임으로써 CPU를 할당받을 확률을 높임
- 여전히 공평성이 위배되어 많이 사용되지 않음

라운드 로빈 스케줄링의 동작 방식

- 한 프로세스가 할당받은 시간(타임 슬라이스) 동안 작업을 하다가 작업을 완료하지
 못하면 준비 큐의 맨 뒤로 가서 자기 차례를 기다리는 방식
- 선점형 알고리즘 중 가장 단순하고 대표적인 방식
- 프로세스들이 작업을 완료할 때까지 계속 순환하면서 실행

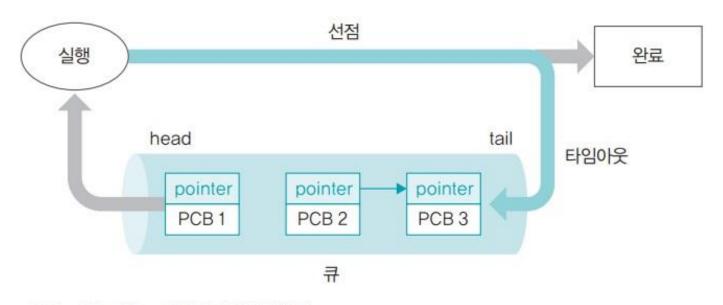


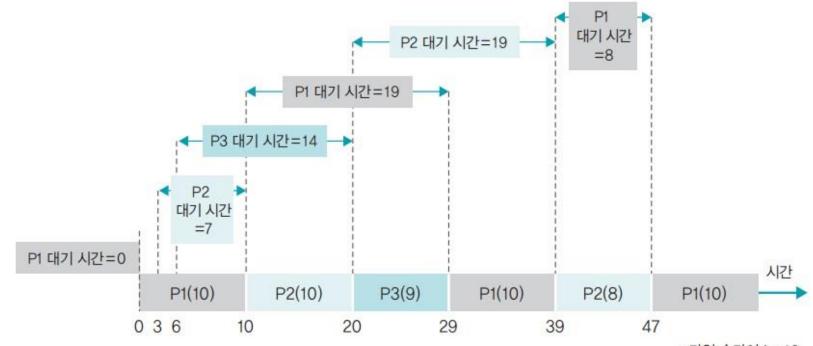
그림 4-20 라운드 로빈 스케줄링의 동작

📘 라운드 로빈 스케줄링의 성능

도착순서	도착시간	작업 시간	
P1	0	30	
P2	3	18	
P3 6		9	

※ 총 대기 시간 0(P1)+7(P2)+14(P3)+19(P1)+19(P2)+8(P1)=67밀리초

※ 평균 대기 시간 67÷3=22.33밀리초



* 타임 슬라이스=10

타임 슬라이스의 크기와 문맥 교환

라운드 로빈 스케줄링이 효과적으로 작동하려면 문맥 교환에 따른 추가 시간을 고려하여 타임 슬라이스를 적절히 설정해야 함

■ 타임 슬라이스가 큰 경우

하나의 작업이 끝난 뒤 다음 작업이 시작되는 것처럼 보여 FCFS 스케줄링과 다를
 게 없음

타임 슬라이스가 작은 경우

 문맥 교환이 너무 자주 일어나 문맥 교환에 걸리는 시간이 실제 작업 시간보다 상 대적으로 커지며, 문맥 교환에 많은 시간을 낭비하여 실제 작업을 못하는 문제가 발생

정리 정리

- 타임 슬라이스는 되도록 작게 설정하되 문맥 교환에 걸리는 시간을 고려하여 적당
 한 크기로 하는 것이 중요
- 유닉스 운영체제에서는 타임 슬라이스가 대략 100 밀리초



4-6 SRT 우선 스케줄링

■ SRT 스케줄링의 동작 방식

■ 기본적으로 라운드 로빈 스케줄링을 사용하지만, CPU를 할당받을 프로세스를 선택할 때 남아 있는 작업 시간이 가장 적은 프로세스를 선택

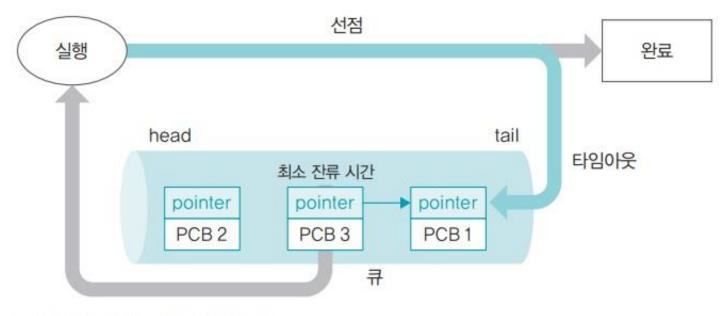


그림 4-23 SRT 스케줄링의 동작

4-6 SRT 우선 스케줄링

■ SRT 스케줄링의 성능

도착 순서	도착시간	시간 작업 시간	
P1	0 30		
P2	3	18	
P3	6	9	

※ 평균 대기 시간 47÷3=15.66밀리초

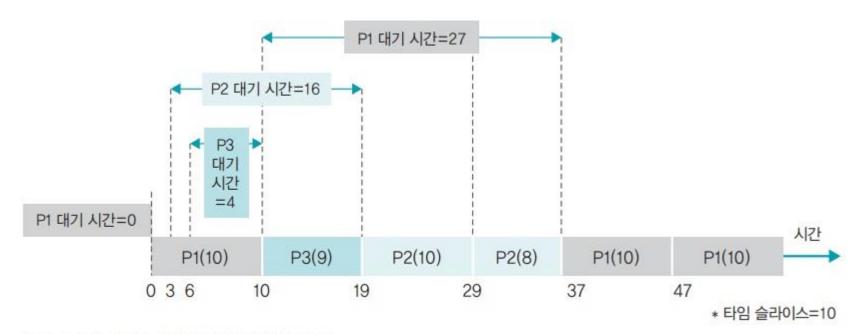


그림 4-24 SRT 스케줄링의 평균 대기 시간

4-6 SRT 우선 스케줄링

■ SRT 스케줄링의 평가

- 현재 실행 중인 프로세스와 큐에 있는 프로세스의 남은 시간을 주기적으로 계산하고, 남은 시간이 더 적은 프로세스와 문맥 교환을 해야 하므로 SJF 스케줄링에는 없는 작업이 추가됨
- 운영체제가 프로세스의 종료 시간을 예측하기 어렵고 아사 현상이 일어나기 때문 에 잘 사용하지 않음

우선순위 스케줄링의 동작 방식

■ 프로세스의 중요도에 따른 우선순위를 반영한 스케줄링 알고리즘

표 4-5 프로세스의 우선순위

도착 순서	도착시간	작업 시간	우선순위
P1	0	30	3
P2	3	18	2
P3	6	9	1

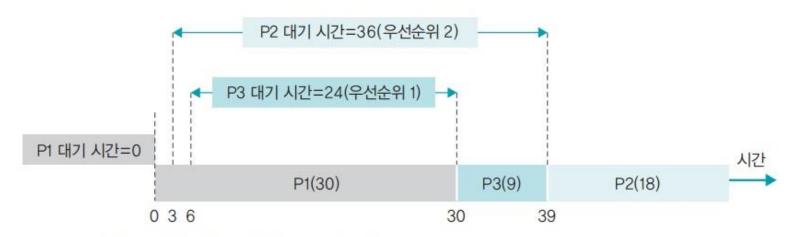


그림 4-25 FCFS 스케줄링에 우선순위를 적용한 결과

📘 우선순위 적용

- 우선순위는 비선점형 방식과 선점형 방식에 모두 적용할 수 있음
 - (비선점형 방식) SJF 스케줄링 : 작업 시간이 짧은 프로세스에 높은 우선순위를 부여
 - (비선점형 방식) HRN 스케줄링 : 작업 시간이 짧거나 대기 시간이 긴 프로세 스에 높은 우선순위를 부여
 - (선점형 방식) SRT 스케줄링 : 남은 시간이 짧은 프로세스에 높은 우선순위를 부여

■ 고정 우선순위 알고리즘

- 한 번 우선순위를 부여받으면 종료될 때까지 우선순위가 고정
- 단순하게 구현할 수 있지만 시시각각 변하는 시스템의 상황을 반영하지 못해 효율
 성이 떨어짐

변동 우선순위 알고리즘

- 일정 시간마다 우선순위가 변하여 일정 시간마다 우선순위를 새로 계산하고 이를 반영
- 복잡하지만 시스템의 상황을 반영하여 효율적인 운영 가능

우선순위 스케줄링의 평가

- 준비 큐에 있는 프로세스의 순서를 무시하고 우선순위가 높은 프로세스에 먼저 CPU를 할당하므로 공평성을 위배하고 아사 현상을 일으킴
- 준비 큐에 있는 프로세스의 순서를 무시하고 프로세스의 우선순위를 매번 바꿔야 하기 때문에 오버헤드가 발생하여 시스템의 효율성을 떨어뜨림

4-8 다단계 큐 스케줄링

다단계 큐 스케줄링의 동작 방식

- 우선순위에 따라 준비 큐를 여러 개 사용하는 방식
- 프로세스는 운영체제로부터 부여받은 우선순위에 따라 해당 우선순위의 큐에 삽입
- 우선순위는 고정형 우선순위를 사용
- 상단의 큐에 있는 모든 프로세스의 작업이 끝나야 다음 우선순위 큐의 작업이 시작됨

4-8 다단계 큐 스케줄링

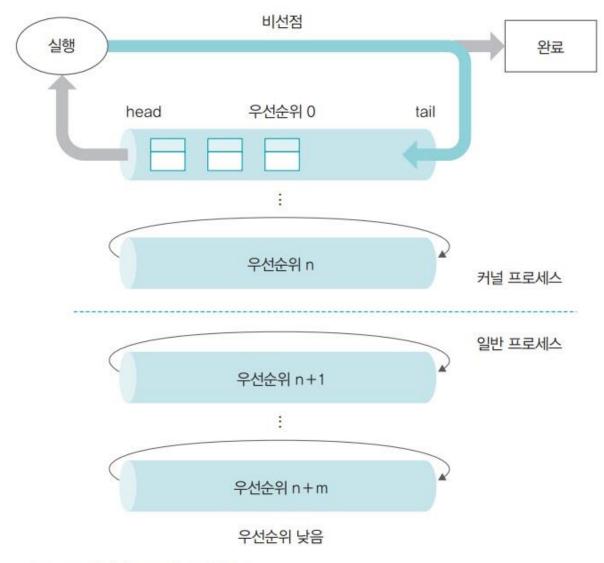


그림 4-26 다단계 큐 스케줄링의 동작

4-9 다단계 피드백 큐 스케줄링

다단계 피드백 큐 스케줄링의 동작 방식

- 프로세스가 CPU를 한 번씩 할당받아 실행될 때마다 프로세스의 우선순위를 낮춤으로써, 다단계 큐에서 우선순위가 낮은 프로세스의 실행이 연기되는 문제를 완화
- 우선순위가 낮아진다고 할지라도 커널 프로세스가 일반 프로세스의 큐에 삽입되지는
 않음
- 우선순위에 따라 타임 슬라이스의 크기가 다름
- 우선순위가 낮아질수록 CPU를 얻을 확률이 적어짐. 따라서 한번 CPU를 잡을 때 많이
 작업하라고 낮은 우선순위의 타임 슬라이스를 크게 함.
- 마지막 큐에 있는(우선순위가 가장 낮은) 프로세스는 무한대의 타임 슬라이스를 얻음
- 마지막 큐는 들어온 순서대로 작업을 마치는 FCFS 스케줄링 방식으로 동작

4-9 다단계 피드백 큐 스케줄링

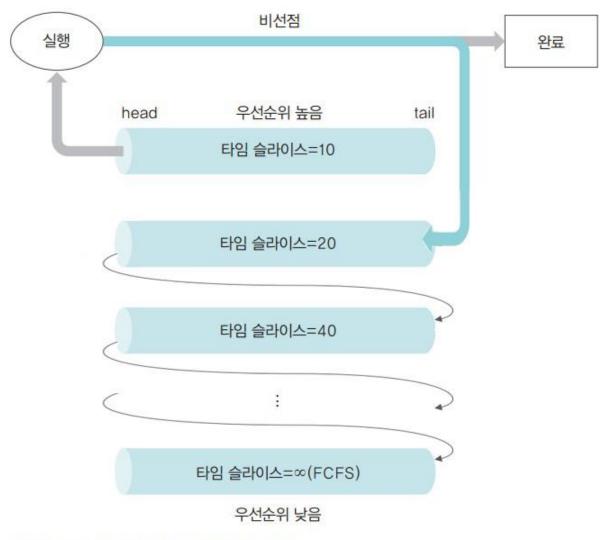


그림 4-27 다단계 피드백 큐 스케줄링의 동작

심화학습 5-1 인터럽트의 개념

■ 폴링

입출력을 요청하면 운영체제가 주기적으로 입출력장치를 직접 확인해서 처리하는
 방식

■ 인터럽트

 이벤트 드리븐 방식과 마찬가지로 입출력을 요청하고 입출력이 완료되면 이벤트를 발생시켜 알림

5-2 동기적 인터럽트와 비동기적 인터럽트

■ 동기적 인터럽트

- 프로세스가 실행 중인 명령어로 인해 발생
- 동기적 인터럽트의 종류
 - 프로그램상의 문제 때문에 발생하는 인터럽트(예: 다른 사용자의 메모리 영역에 접근하는 경우, 오버플로나 언더플로에 의해 발생하는 경우 등)
 - 컴퓨터 작업자가 의도적으로 프로세스를 중단하기 위해 발생시킨 인터럽트(예: [Ctrl]+[C])
 - 입출력장치 같은 주변장치의 조작에 의한 인터럽트
 - 산술 연산 중 발생하는 인터럽트(예: 어떤 수를 0으로 나눔)

■ 비동기적 인터럽트

- 하드디스크 읽기 오류, 메모리 불량과 같은 하드웨어적인 오류로 발생
- 사용자가 직접 작동하는 키보드 인터럽트, 마우스 인터럽트 등이 있음

5-3 인터럽트 처리 과정

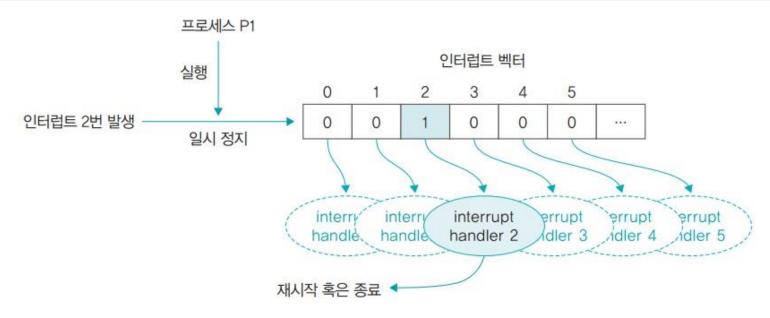


그림 4-30 인터럽트 처리 과정

- 인터럽트가 발생하면 현재 실행 중인 프로세스는 일시 정지 상태가 되며, 재시작하기 위해 현재 프로세스 관련 정보를 임시로 저장
- ❷ 인터럽트 컨트롤러가 실행되어 인터럽트의 처리 순서를 결정
- ❸ 먼저 처리할 인터럽트가 결정되면 인터럽트 벡터에 등록된 인터럽트 핸들러가 실행
- ◆ 인터럽트 벡터에 연결된 핸들러가 인터럽트 처리를 마치면 일시정지된 프로세스가 다시 실행되거나 종료

5-4 인터럽트와 이중 모드

📘 커널 모드

■ 운영체제와 관련된 커널 프로세스가 실행되는 상태

■ 사용자 모드

■ 사용자 프로세스가 실행되는 상태

■ 이중 모드

- 운영체제가 커널 모드와 사용자 모드를 전환하며 일 처리를 하는 것
- 궁극적인 목적은 자원 보호에 있음

5-4 인터럽트와 이중 모드

■ 시스템 호출과 API

- 사용자 프로세스가 자원에 접근하려면 시스템 호출을 이용해야 함
- 사용자 프로세스는 API가 준비해놓은 다양한 함수를 이용하여 시스템 자원에 접근

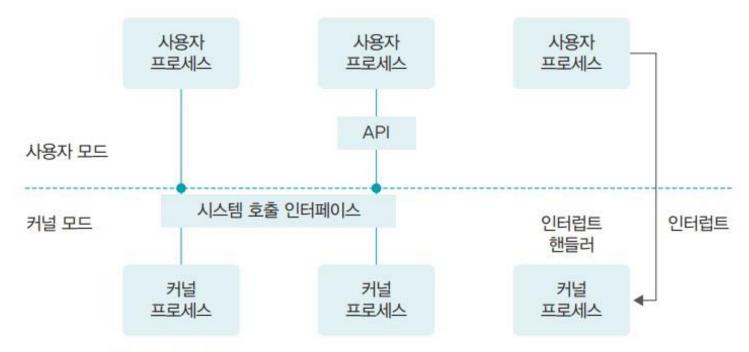


그림 4-31 시스템 호출과 API

Thank You